ĐẠI HỌC QUỐC GIA TPHCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

Báo cáo thực nghiệm huấn luyện mô hình

Đề tài: ENGLISH–VIETNAMESE PARALLEL SENSE TAGGER

Môn học: Nhập môn Xử lý ngôn ngữ tự nhiên

Sinh viên thực hiện:

Nguyễn Đức Anh - 23127022

Châu Trung Kỳ - 23127079

Từ Thế Phong - 23127101

Phan Thanh Bình - 23127028

Giáo viên hướng dẫn:

Thầy Đinh Điền

Thầy Nguyễn Hồng Bửu Long

Thầy Lương An Vinh

Ngày 4 tháng 1 năm 2026

Mục lục

Phần I. Mục tiêu và phạm vi công việc **2**
1.1. Giới thiệu bài toán . . . 2
1.2. Mục tiêu và phạm vi công việc . . . 3
1.3. Tập dữ liệu . . . 3
1.3. Phương pháp . . . 4

Phần II. Cấu trúc hệ thống và quản lý dữ liệu trên cloud **4**
2.1. Môi trường thực thi . . . 4
2.2. Tổ chức thư mục dự án . . . 5

Phần III. Phương pháp mô hình hóa (Methodology) **5**
3.1. Kiến trúc mô hình . . . 6
3.2. Chiến lược xử lý dữ liệu . . . 6
3.3. Loss Function (Hàm mất mát) . . . 7

Phần IV. Thiết lập thực nghiệm **8**
4.1. Tham số huấn luyện . . . 8
4.2. Tối ưu hóa . . . 9

Phần V. Kết quả và đánh giá **10**
5.1. Độ đo đánh giá . . . 10
5.2. Kết quả thực tế . . . 10
5.3. Phân tích . . . 11

Phần VI. Kết luận và hướng phát triển **12**
6.1. Kết luận . . . 12
6.2. Hướng phát triển . . . 13

Phần VII. Tài liệu tham khảo **14**

Phần I. Mục tiêu và phạm vi công việc

1.1. Giới thiệu bài toán

Trong xử lý ngôn ngữ tự nhiên, tính nhập nhằng ngữ nghĩa (semantic ambiguity) là một trong những thách thức là một vấn đề cơ bản. Một từ có thể mang nhiều nghĩa khác nhau tùy ngữ cảnh, và việc xác định đúng nghĩa của từ là nền tảng cho các bài toán như dịch máy hay phân tích ngữ nghĩa.

Tiếng Anh có mức độ đa nghĩa cao, trong khi ngữ cảnh đơn ngữ không phải lúc nào cũng đủ rõ để phân biệt nghĩa, đặc biệt với các câu ngắn. Trong khi đó, bản dịch tiếng Việt thường làm rõ hơn nghĩa cụ thể của từ thông qua lựa chọn từ vựng khi dịch.

Ví dụ minh họa:

Với từ "light",

- Câu tiếng Anh: "He carried a light bag". Nếu chỉ xét riêng tiếng Anh, từ "light" trong bối cảnh này có thể hiểu là "nhẹ" hoặc "nhạt màu". Nếu chỉ dựa vào câu tiếng Anh, việc xác định nghĩa của light vẫn có thể gây nhập nhằng.

- Câu tiếng Việt tương ứng: "Anh ấy mang một chiếc túi nhẹ." Thông qua bản dịch tiếng Việt, từ “nhẹ” làm rõ rằng “light” trong trường hợp này mang nghĩa “not heavy”, giúp loại bỏ hoàn toàn các nghĩa còn lại.

Với từ "bank",

- Câu tiếng Anh: "They sat near the bank." Trong tiếng Anh, "bank" ở đây có thể mang hai nghĩa "ngân hàng" hoặc "bờ sông".

- Câu tiếng Việt tương ứng: "Họ ngồi gần bờ sông".Bản dịch tiếng Việt làm rõ nghĩa “bờ sông”, giúp xác định chính xác sense của từ bank trong ngữ cảnh này.

Dựa trên quan sát này, bài toán English–Vietnamese Parallel Sense Tagger khai thác dữ liệu song ngữ như một tín hiệu ngữ nghĩa bổ sung để hỗ trợ phân biệt và gán nhãn nghĩa cho các từ đa nghĩa. Trong khuôn khổ đồ án, thay vì dừng lại ở bước xử lý dữ liệu, nhóm tập trung vào việc xây dựng và huấn luyện mô hình học sâu dựa trên kiến trúc XLM-RoBERTa. Tận dụng bộ dữ liệu 50.000 cặp câu song song đã được gán nhãn và căn chỉnh kỹ lưỡng trước đó làm đầu vào để tinh chỉnh

(fine-tune) mô hình, tối ưu hóa hàm mất mát hỗn hợp nhằm giải quyết bài toán phân giải nghĩa đa ngữ một cách hiệu quả.

1.2. Mục tiêu và phạm vi công việc

Mục tiêu cốt lõi của đồ án là hiện thực hóa quy trình huấn luyện một mô hình học sâu có khả năng gán nhãn nghĩa tự động cho các từ đa nghĩa trong môi trường song ngữ Anh-Việt. Thay vì chỉ dừng lại ở việc xử lý dữ liệu thô, nhóm tập trung vào việc xây dựng một pipeline huấn luyện hoàn chỉnh, từ việc nạp dữ liệu, thiết kế kiến trúc mạng nơ-ron đến việc tối ưu hóa các tham số để đạt được độ chính xác cao nhất. Mô hình hướng tới việc không chỉ dự đoán đúng nghĩa của từ trong từng ngôn ngữ riêng biệt mà còn phải tận dụng được mối tương quan ngữ nghĩa giữa cặp câu song song để cải thiện hiệu năng tổng thể.

Về phạm vi công việc, đồ án giới hạn nghiên cứu trong việc ứng dụng kỹ thuật Fine-tuning mô hình ngôn ngữ tiền huấn luyện đa ngữ, cụ thể là kiến trúc XLM-RoBERTa (phiên bản Base). Môi trường thực nghiệm được triển khai trên nền tảng cloud Google Colab, xử lý tập dữ liệu đóng gồm khoảng 50.000 mẫu.Thiết lập cơ chế đánh giá mô hình và lưu trữ các trọng số tối ưu sau quá trình huấn luyện.

1.3. Tập dữ liệu

Đồ án sử dụng nguồn dữ liệu đầu vào là tập hợp khoảng 50.000 cặp câu song song Anh-Việt đã trải qua quy trình tiền xử lý, bao gồm các bước căn chỉnh từ (alignment) và gán nhãn nghĩa thủ công hoặc bán tự động (có sự hỗ trợ của chat model) ở giai đoạn trước. Dữ liệu này được lưu trữ dưới định dạng JSON Lines (.jsonl), trong đó mỗi mẫu dữ liệu chứa đầy đủ thông tin về các tokens và nhãn nghĩa tương ứng cho cả hai ngôn ngữ, đảm bảo tính cấu trúc và thuận tiện cho việc truy xuất bằng máy tính. Bên cạnh dữ liệu câu, nhóm còn chuẩn bị các tệp từ điển ánh xạ (mapping dictionaries) để chuyển đổi giữa nhãn nghĩa dạng văn bản và định danh số, phục vụ cho quá trình tính toán của mô hình.

Để đảm bảo tính khách quan trong việc đánh giá hiệu năng mô hình và kiểm soát hiện tượng quá khớp (overfitting), tập dữ liệu toàn cục được phân chia ngẫu nhiên thành hai phần riêng biệt ngay trước khi bước vào quá trình huấn luyện. Cụ thể, 80% dữ liệu được sử dụng làm tập huấn luyện (Training set) để mô hình học các đặc trưng và cập nhật trọng số, trong khi 20% còn lại được tách

riêng làm tập kiểm thử (Development set).

1.3. Phương pháp

Để giải quyết bài toán gán nhãn nghĩa song ngữ, nhóm đề xuất phương pháp tiếp cận dựa trên mô hình học chuyển tiếp (Transfer Learning) với kiến trúc XLM-RoBERTa (XLM-R). Đây là mô hình Transformer hiện đại được huấn luyện trên lượng dữ liệu khổng lồ từ 100 ngôn ngữ, cung cấp khả năng biểu diễn ngữ nghĩa vượt trội trong không gian đa ngữ. Kiến trúc hệ thống được thiết kế theo cơ chế chia sẻ bộ mã hóa (Shared Encoder), trong đó cả câu tiếng Anh và tiếng Việt đều đi qua cùng một khối XLM-R để trích xuất các véc-tơ đặc trưng ngữ cảnh. Đầu ra của bộ mã hóa này sau đó được đưa vào hai lớp phân loại tuyến tính (Linear Classifiers) riêng biệt để dự đoán nhãn nghĩa cho từng ngôn ngữ tương ứng.
Chiến lược huấn luyện được tối ưu hóa thông qua việc thiết kế một hàm mất mát hỗn hợp (Hybrid Loss Function). Hàm này là sự kết hợp giữa độ mất mát phân loại (Cross-Entropy Loss) truyền thống trên từng ngôn ngữ và độ mất mát nhất quán song song (Parallel Consistency Loss). Thành phần Consistency Loss sử dụng độ đo tương đồng Cosine để ràng buộc các véc-tơ biểu diễn của các từ tương đương trong hai ngôn ngữ phải gần nhau trong không gian đặc trưng, qua đó giúp mô hình tận dụng tối đa tín hiệu từ bản dịch để gỡ lỗi nhập nhằng về nghĩa. Quá trình tối ưu hóa sử dụng thuật toán AdamW kết hợp với kỹ thuật điều chỉnh tốc độ học phân tầng (Differential Learning Rates), cho phép giữ lại tri thức nền của lớp Encoder trong khi nhanh chóng cập nhật các lớp phân loại cho tác vụ mới.

Phần II. Cấu trúc hệ thống và quản lý dữ liệu trên cloud

2.1. Môi trường thực thi

Hệ thống huấn luyện được triển khai trên nền tảng ***Google Colab***, tận dụng tài nguyên tính toán đám mây để xử lý các tác vụ học sâu *(Deep Learning)* tốn kém tài nguyên. Cấu hình cụ thể bao gồm:

- Phần cứng: Sử dụng GPU (được cấp phát động bởi Colab, thường là NVIDIA T4 hoặc P100) để tăng tốc quá trình huấn luyện mô hình Transformer.

- Thư viện lõi: Hệ thống được xây dựng trên nền tảng PyTorch, sử dụng thư viện Transformers (HuggingFace) để tải pre-trained model XLM-R, và Scikit-learn cho các phép đo đánh giá.
- Cơ chế lưu trữ: Dữ liệu và mô hình được lưu trữ bền vững trên Google Drive và được gắn kết (mount) trực tiếp vào môi trường runtime của Colab để đảm bảo tính toàn vẹn dữ liệu qua các phiên làm việc.

2.2. Tổ chức thư mục dự án

Để đảm bảo quy trình huấn luyện diễn ra tự động và có tổ chức, cấu trúc thư mục trên Google Drive được quy hoạch tại đường dẫn gốc `BASE_DIR = "/content/drive/MyDrive/en_vi_sense_tagger"`. Sơ đồ tổ chức cụ thể như sau:

- `en_vi_sense_tagger/`
  - `data/`: Chứa toàn bộ dữ liệu phục vụ huấn luyện và từ điển.
    - `dataset.jsonl`: Tập dữ liệu thô đầu vào (chứa các cặp câu song ngữ và nhãn).
    - `dataset_train.jsonl` và `dataset_dev.jsonl`: Các tệp dữ liệu sau khi được code tự động chia tách (split) để cố định tập huấn luyện và kiểm thử.
    - `en_sense_list.json` và `vi_sense_list.json`: Từ điển ánh xạ (Mapping) dùng để chuyển đổi giữa nhãn nghĩa (text) và ID (số).
  - `model/`: Nơi lưu trữ trọng số mô hình (Checkpoints).
    - `best_model.pt`: Checkpoint của mô hình có chỉ số F1 trung bình cao nhất, được lưu tự động trong quá trình huấn luyện.
  - `test_output/`:Chứa các kết quả dự đoán hoặc log đánh giá sau khi chạy thực nghiệm.

Cơ chế hoạt động: Đoạn mã khởi động sẽ thực hiện lệnh `drive.mount("/content/drive")`, cho phép mã nguồn truy cập trực tiếp vào các đường dẫn trên như một hệ thống tập tin cục bộ (Local File System).

Phần III. Phương pháp mô hình hóa (Methodology)

Hệ thống được xây dựng dựa trên mô hình ngôn ngữ tiền huấn luyện đa ngôn ngữ (Multilingual Pre-trained Language Model) với kiến trúc tùy chỉnh để giải quyết bài toán gán nhãn nghĩa song

song cho tiếng Anh và tiếng Việt.

3.1. Kiến trúc mô hình

Nhóm đề xuất mô hình **XLMRParallelSenseTagger**, được xây dựng dựa trên nền tảng **XLM-RoBERTa Base** (XLM-R). Kiến trúc tổng thể tuân theo cơ chế "Shared Encoder - Separate Classifiers". Cụ thể, mô hình bao gồm các thành phần sau:

- **Shared Encoder (Bộ mã hóa dùng chung):** Sử dụng ‘xlm-roberta-base‘ làm backbone. Encoder này nhận đầu vào là chuỗi token của tiếng Anh hoặc tiếng Việt và chuyển đổi chúng thành các vector đặc trưng ngữ cảnh (contextualized embeddings) có chiều $d_{model} = 768$. Việc chia sẻ encoder giúp mô hình học được sự tương đồng ngữ nghĩa giữa hai ngôn ngữ trong không gian vector chung.
- **Dropout Layer:** Một lớp Dropout với tỷ lệ $p = 0.1$ được áp dụng sau đầu ra của encoder để giảm thiểu hiện tượng overfitting.
- **Task-specific Classifiers (Các bộ phân lớp riêng biệt):** Thay vì sử dụng một đầu ra chung, nhóm thiết kế hai lớp Linear (Fully Connected) riêng biệt cho từng ngôn ngữ:
  - **English Classifier:** Ánh xạ vector đặc trưng sang không gian nhãn của WordNet tiếng Anh (N_{en} nhãn).
  - **Vietnamese Classifier:** Ánh xạ vector đặc trưng sang không gian nhãn của WordNet tiếng Việt (N_{vi} nhãn).

Quá trình lan truyền xuôi được thực hiện song song: Batch tiếng Anh và Batch tiếng Việt được đưa qua cùng một encoder, sau đó đi qua các classifier tương ứng để tạo ra phân phối xác suất trên các tập nhãn.

3.2. Chiến lược xử lý dữ liệu

Dữ liệu đầu vào ở định dạng JSONL chứa các cặp câu song ngữ đã được gán nhãn (Word Sense Disambiguation labels). Quá trình tiền xử lý dữ liệu được thực hiện thông qua lớp ‘ParallelSenseDataset‘ với các chiến lược chính sau:

1. **Tokenization & Sub-word Alignment:** Mô hình sử dụng tokenizer của XLM-RoBERTa (SentencePiece). Do tokenizer này chia một từ gốc thành nhiều sub-word, nhóm áp dụng chiến lược **First-Token Tagging**:
   - Nhãn của từ gốc chỉ được gán cho sub-word đầu tiên.
   - Các sub-word tiếp theo của cùng một từ được gán nhãn đặc biệt `IGNORE_INDEX` (giá trị -100). Điều này đảm bảo loss function không tính toán lỗi cho các phần tử phụ này.
2. **Xử lý nhãn OOV (Out-of-Vocabulary Senses):** Trong quá trình huấn luyện, nếu gặp một nhãn ngữ nghĩa (sense ID) không tồn tại trong từ điển nhãn đã xây dựng (‘`label_map`‘), hệ thống sẽ tự động quy hoạch nhãn đó về nhãn mặc định "O" (Outside) để đảm bảo tính ổn định của mô hình.
3. **Input Formatting:** Mỗi mẫu dữ liệu bao gồm cặp input ‘(en, vi)‘. Các chuỗi được cắt hoặc đệm (padding) về độ dài cố định $L_{max} = 128$.

3.3. Loss Function (Hàm mất mát)

Để tối ưu hóa mô hình cho cả hai ngôn ngữ đồng thời tận dụng sự tương đồng ngữ nghĩa song ngữ, nhóm thiết kế một hàm mất mát tổng hợp (Composite Loss Function). Tổng loss $\mathcal{L}_{total}$ là tổng có trọng số của ba thành phần:

$$\mathcal{L}_{total} = \mathcal{L}_{en} + \mathcal{L}_{vi} + \lambda \cdot \mathcal{L}_{parallel}$$

Trong đó:

- $\mathcal{L}_{en}$ và $\mathcal{L}_{vi}$: Là **Cross-Entropy Loss** tiêu chuẩn cho bài toán phân loại token (Supervised Loss). Hàm này chỉ tính toán trên các token có nhãn hợp lệ (bỏ qua các vị trí có nhãn -100).
- $\mathcal{L}_{parallel}$ (Parallel Consistency Loss): Là thành phần loss tự giám sát nhằm kéo gần khoảng cách giữa biểu diễn vector của các từ có nghĩa tương đương trong hai ngôn ngữ. Loss này được tính toán dựa trên độ tương đồng Cosine giữa vector ẩn (hidden states) của tiếng Anh (h_{en}) và tiếng Việt (h_{vi}) tại các vị trí từ mang nghĩa (không phải nhãn ’O’ hoặc Padding):

$$\mathcal{L}_{parallel} = \text{mean}(1 - \text{cosine_similarity}(h_{en}, h_{vi}))$$

- λ: Hệ số siêu tham số điều chỉnh tầm quan trọng của tính nhất quán song ngữ, được thiết lập là 0.1 trong thực nghiệm.

Cơ chế này khuyến khích mô hình tạo ra các biểu diễn ngữ nghĩa tương tự nhau cho các cặp từ song song, giúp cải thiện khả năng chuyển giao tri thức.

Phần IV. Thiết lập thực nghiệm

Trong phần này, nhóm mô tả chi tiết các thiết lập kỹ thuật, cấu hình tham số và quy trình tối ưu hóa dựa trên pipeline huấn luyện đã xây dựng cho mô hình **XLMRParallelSenseTagger**.

4.1. Tham số huấn luyện

Để đảm bảo tính ổn định và khả năng tái lập (reproducibility) của thực nghiệm, nhóm thiết lập giá trị hạt giống ngẫu nhiên (*Seed*) cố định là 42. Các tham số huấn luyện cụ thể được cấu hình như sau:

- **Môi trường và Thư viện:** Hệ thống được triển khai trên nền tảng Google Colab, sử dụng GPU NVIDIA T4. Các thư viện cốt lõi bao gồm `PyTorch` (huấn luyện mô hình), `Transformers` (Hugging Face) và `Scikit-learn`.
- **Cấu hình Batching và Tăng tốc:**
  - Kích thước lô (*Batch Size*): 10 mẫu/bước.
  - Tích lũy gradient (*Gradient Accumulation*): 2 bước, tạo ra kích thước lô hiệu dụng là 20 để ổn định quá trình cập nhật trọng số.
  - Huấn luyện chính xác hỗn hợp (*FP16 Mixed Precision*): Sử dụng `GradScaler` nhằm tăng tốc độ tính toán và tối ưu dung lượng bộ nhớ GPU.
- **Thông số kỹ thuật:**
  - Số lượng kỷ nguyên (*Epochs*): 6.
  - Độ dài chuỗi tối đa (L_{max}): 128 tokens.
  - Tỷ lệ phân chia Train/Dev: 90%/10%.

Bảng 1: Tóm tắt các thông số thiết lập thực nghiệm

Tham số	**Giá trị**
Mô hình nền tảng	`xlm-roberta-base`
Hạt giống (Seed)	42
Số lượng Epochs	6
Tốc độ học Encoder	2×10^{-5}
Tốc độ học Classifiers	1×10^{-4}
Hệ số $\lambda_{parallel}$	0.1
Ngưỡng cắt Gradient	1.0

4.2. Tối ưu hóa

Quy trình tối ưu hóa được tinh chỉnh để phù hợp với kiến trúc đa ngôn ngữ và các tầng phân loại riêng biệt:

1. **Tốc độ học phân tầng (Differential Learning Rate):** Nhóm áp dụng chiến lược tốc độ học không đồng nhất để tối ưu hiệu quả:
   - **Bộ mã hóa (Encoder):** Sử dụng mức 2×10^{-5} để tinh chỉnh nhẹ nhàng các trọng số đã được huấn luyện sẵn.
   - **Bộ phân lớp (Classifiers):** Sử dụng mức 1×10^{-4} (cao hơn 5 lần) để các tầng Linear mới nhanh chóng học được cách ánh xạ vector đặc trưng sang không gian nhãn nghĩa.
2. **Thuật toán tối ưu:** Sử dụng **AdamW** với hệ số *Weight Decay* là 0.01. Để đảm bảo quá trình huấn luyện không bị mất ổn định, kỹ thuật **Gradient Clipping** (`max_norm = 1.0`) được sử dụng trước mỗi bước cập nhật trọng số.
3. **Tính toán hàm mất mát:**
   - Hàm mất mát giám sát (Supervised Loss) sử dụng `CrossEntropyLoss` với `ignore_index = -100` để loại bỏ các sub-word phụ và nhãn đệm khỏi quá trình tối ưu.
   - Hàm mất mát nhất quán ($\mathcal{L}_{parallel}$) được tính dựa trên độ tương đồng Cosine của các vector ẩn tại các vị trí từ mang nghĩa, với trọng số điều chỉnh $\lambda = 0.1$.
4. **Chiến lược lưu trữ:** Sau mỗi epoch, hệ thống tiến hành đánh giá trên tập phát triển (*Dev set*). Phiên bản mô hình đạt chỉ số F1 trung bình cao nhất giữa hai ngôn ngữ (*Best AVG F1*) sẽ được lưu lại làm mô hình cuối cùng để dự đoán thực tế.

Phần V. Kết quả và đánh giá

5.1. Độ đo đánh giá

Trong nghiên cứu này, việc đánh giá mô hình được thực hiện theo hai pha riêng biệt, tương ứng với hai tập dữ liệu khác nhau: tập phát triển (development set) có nhãn và tập kiểm tra (test set) không có nhãn.

Đối với tập phát triển, nhóm sử dụng các độ đo đánh giá chuẩn trong bài toán gán nhãn ở mức token, bao gồm Precision, Recall và F1-score (micro-averaged). Các độ đo này được tính riêng cho tiếng Anh và tiếng Việt, đồng thời báo cáo thêm giá trị trung bình nhằm phản ánh hiệu năng tổng thể của mô hình.

Đối với tập kiểm tra, do không có nhãn chuẩn ở mức token, các độ đo đánh giá truyền thống như Precision, Recall hay F1-score không thể áp dụng trực tiếp. Thay vào đó, nhóm sử dụng các độ đo gián tiếp và phân tích định tính, bao gồm:

- Tỷ lệ token được gán nhãn nghĩa khác `O`, nhằm đánh giá mức độ thận trọng của mô hình trong việc gán nhãn.
- Độ tương đồng cosine trung bình giữa embedding ngữ cảnh của các token mang nghĩa trong các cặp câu Anh–Việt, nhằm đánh giá tính nhất quán ngữ nghĩa song ngữ.

Các độ đo này cho phép đánh giá hành vi của mô hình trong kịch bản suy luận thực tế, đồng thời phản ánh trực tiếp mục tiêu của bài toán gán nhãn nghĩa song song Anh–Việt.

5.2. Kết quả thực tế

Kết quả trên tập phát triển

Tập phát triển bao gồm 4,949 cặp câu song song Anh–Việt với nhãn nghĩa ở mức token, được trích ra từ tổng cộng 49,484 mẫu dữ liệu. Phần còn lại gồm 44,535 mẫu được sử dụng cho huấn luyện mô hình.

Bảng 2 trình bày kết quả huấn luyện và đánh giá mô hình trên tập phát triển theo từng epoch. Có thể quan sát thấy rằng hàm mất mát trong quá trình huấn luyện giảm đều qua các epoch, trong khi F1-score trên tập phát triển tăng ổn định trong giai đoạn đầu và dần đạt trạng thái bão hòa.

Bảng 2: Kết quả đánh giá trên tập phát triển theo từng epoch (token-level micro-F1)

Epoch	Train Loss	EN F1	VI F1	AVG F1
1	2946.63	0.9630	0.8881	0.9255
2	1530.06	0.9667	0.8933	0.9300
3	1316.57	0.9676	0.8951	0.9313
4	**1181.06**	**0.9690**	**0.8981**	**0.9336**
5	1085.99	0.9691	0.8974	0.9332
6	999.10	0.9694	0.8969	0.9332

Epoch thứ 4 đạt giá trị F1 trung bình cao nhất và được lựa chọn làm mô hình tốt nhất để sử dụng cho pha đánh giá tiếp theo.

Kết quả trên tập kiểm tra

Tập kiểm tra bao gồm các cặp câu Anh–Việt chưa được gán nhãn và chưa được tách token. Trên tập dữ liệu này, mô hình được sử dụng để suy luận và thu thập các thống kê mô tả.
Kết quả cho thấy mô hình gán nhãn nghĩa cho khoảng 9.67% số token tiếng Anh và 5.17% số token tiếng Việt, như trình bày trong Bảng 3.

Bảng 3: Tỷ lệ token được gán nhãn nghĩa trên tập kiểm tra

Ngôn ngữ	Tỷ lệ token có nhãn nghĩa (%)
Tiếng Anh	9.67
Tiếng Việt	5.17

Ngoài ra, độ tương đồng cosine trung bình giữa embedding ngữ cảnh của các token mang nghĩa trong các cặp câu Anh–Việt đạt giá trị **0.5468**, cho thấy mức độ nhất quán ngữ nghĩa đáng kể giữa hai ngôn ngữ trong không gian biểu diễn chung.

5.3. Phân tích

Các kết quả thu được cho thấy mô hình đạt hiệu năng cao và ổn định trên tập phát triển, đồng thời thể hiện khả năng tổng quát hóa hợp lý khi được áp dụng lên tập kiểm tra không có nhãn.
Tỷ lệ token được gán nhãn nghĩa tương đối thấp trên tập kiểm tra cho thấy mô hình có xu hướng thận trọng, chủ yếu gán nhãn cho các từ mang nội dung ngữ nghĩa rõ ràng như động từ và danh từ nội dung, trong khi các từ chức năng phần lớn được gán nhãn `O`. Đây là hành vi mong muốn trong bài toán gán nhãn nghĩa, giúp giảm hiện tượng gán nhãn quá mức.

Độ tương đồng cosine trung bình ở mức 0.5468 cho thấy mô hình đã học được một không gian biểu diễn chung, trong đó các token mang ngữ nghĩa tương ứng giữa tiếng Anh và tiếng Việt có xu hướng nằm gần nhau. Kết quả này khẳng định hiệu quả của kiến trúc encoder dùng chung kết hợp với huấn luyện song ngữ trong việc nắm bắt quan hệ ngữ nghĩa xuyên ngôn ngữ.
Mặc dù vậy, mô hình vẫn gặp khó khăn đối với các từ đa nghĩa cao, các nghĩa hiếm, cũng như các thành ngữ và cụm từ cố định. Những hạn chế này gợi ý các hướng cải tiến trong tương lai, chẳng hạn như mô hình hóa ở mức cụm từ hoặc tích hợp thêm thông tin căn chỉnh song ngữ rõ ràng hơn.

Phần VI. Kết luận và hướng phát triển

6.1. Kết luận

Đồ án đã hoàn thành mục tiêu xây dựng và huấn luyện hệ thống **XLMRParallelSenseTagger** phục vụ bài toán gán nhãn nghĩa song ngữ Anh–Việt. Thông qua quá trình thực hiện thực nghiệm và triển khai pipeline, nhóm rút ra các kết luận chính sau:

- **Hiệu quả của kiến trúc chia sẻ:** Việc sử dụng mô hình `xlm-roberta-base` làm Encoder dùng chung đã chứng minh khả năng biểu diễn ngữ nghĩa mạnh mẽ trong không gian đa ngôn ngữ. Kiến trúc "Separate Classifiers" cho phép mô hình linh hoạt thích nghi với các tập nhãn nghĩa (Sense IDs) khác nhau của WordNet tiếng Anh và tiếng Việt.

- **Vai trò của thành phần nhất quán song ngữ:** Việc tích hợp *Parallel Consistency Loss* với hệ số $\lambda = 0.1$ đã giúp mô hình tận dụng sự tương đồng ngữ nghĩa giữa hai ngôn ngữ. Cơ chế này ép buộc các vector đặc trưng ẩn của các từ tương ứng trong cặp câu song ngữ xích lại gần nhau, từ đó cải thiện độ chính xác khi khử nhập nhằng.

- **Tối ưu hóa quy trình huấn luyện:** Các kỹ thuật hiện đại như tốc độ học phân tầng (*Differential Learning Rate*), huấn luyện chính xác hỗn hợp (*FP16*) và tích lũy gradient (*Gradient Accumulation*) đã giúp mô hình hội tụ ổn định và đạt được chỉ số F1 tối ưu trong điều kiện tài nguyên tính toán giới hạn (GPU T4).

- **Xử lý dữ liệu thực tế:** Chiến lược *First-Token Tagging* kết hợp với việc ánh xạ các nhãn nằm ngoài từ điển (OOV) về nhãn mặc định "O" đã giúp hệ thống vận hành trơn tru trên dữ liệu JSONL thực tế, đảm bảo tính nhất quán giữa khâu tokenization và gán nhãn.

Nhìn chung, thực nghiệm đã khẳng định giả thuyết ban đầu: việc sử dụng bản dịch tiếng Việt như một tín hiệu ngữ nghĩa bổ trợ có tác dụng tích cực trong việc xác định chính xác ý nghĩa của các từ đa nghĩa trong tiếng Anh.

6.2. Hướng phát triển

Trong tương lai, để nâng cao hơn nữa hiệu suất và khả năng ứng dụng của mô hình, nhóm đề xuất một số hướng phát triển như sau:

1. **Mở rộng quy mô tri thức:** Tăng cường tập dữ liệu huấn luyện từ các nguồn song ngữ chất lượng cao khác và cập nhật danh sách nghĩa từ các phiên bản mới nhất của WordNet để tăng độ phủ từ vựng.

2. **Thử nghiệm với mô hình ngôn ngữ lớn (LLMs):** Đánh giá khả năng gán nhãn nghĩa của các mô hình như Llama 3 hoặc GPT-4 thông qua cơ chế *Few-shot Prompting* để so sánh với phương pháp *Fine-tuning* truyền thống trên các mô hình Transformer kích thước trung bình.

3. **Tối ưu hóa siêu tham số tự động:** Sử dụng các kỹ thuật như *Bayesian Optimization* để tìm ra bộ tham số tối ưu cho λ và tốc độ học, thay vì thiết lập thủ công, nhằm khai thác tối đa tiềm năng của kiến trúc mô hình.

4. **Triển khai ứng dụng thực tế:** Phát triển giao diện người dùng cho phép nhập vào cặp câu song ngữ và hiển thị kết quả gán nhãn nghĩa trực quan, phục vụ cho các mục đích nghiên cứu ngôn ngữ học đối chiếu hoặc hỗ trợ biên dịch.

5. **Kết hợp thông tin ngữ pháp:** Tích hợp thêm các đặc trưng về từ loại (POS Tagging) hoặc cấu trúc cú pháp để hỗ trợ mô hình phân biệt tốt hơn các từ có cùng mặt chữ nhưng khác chức năng ngữ pháp và ngữ nghĩa.

Phần VII. Tài liệu tham khảo

[1] Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Édouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451. Association for Computational Linguistics, 2020.

[2] Zi-Yi Dou and Graham Neubig. Word alignment by fine-tuning embeddings on parallel corpora. In *Conference of the European Chapter of the Association for Computational Linguistics (EACL)*, 2021.

[3] Minh-Thang Luong and Christopher D. Manning. Stanford neural machine translation systems for spoken language domain. In *International Workshop on Spoken Language Translation*, Da Nang, Vietnam, 2015.

[4] George A. Miller. WordNet: A lexical database for English. In *Human Language Technology: Proceedings of a Workshop held at Plainsboro, New Jersey, March 8-11, 1994*, 1994.

[5] Thomas Wolf, Lysandre Debut, Victor Sanh, Julien Chaumond, Clément Delangue, Anthony Moi, Pierric Cistac, Tim Rault, Rémi Louf, Morgan Funtowicz, and Jamie Brew. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45. Association for Computational Linguistics, 2020.